# Module 2
# Image acquisition & preprocessing

Uwe Springmann

Centrum für Informations- und Sprachverarbeitung (CIS)
Ludwig-Maximilians-Universität München (LMU)

2015-09-14

# Motivation

- remember: the complete OCR workflow consists of several steps:
  1. image acquisition
  2. preprocessing
  3. (ground truth production, model training)
  4. recognition
  5. evaluation
  6. postprocessing: annotation, error correction, tagging, ...
- “a chain is only as strong as its weakest link”:
  bad images/preprocessing will severely limit the quality of your end result
- trade-off: fast result against quality result (requires some manual processing)
- make an informed decision based on your objectives

# Image acquisition

# Where to look for digitized books

- look for scans at HathiTrust, archive.org, Europeana, The European Library, DDB, Wikisource, BSB, or Google books
- try to find the best scan (Google books are often the worst); larger file sizes point to higher resolution
- especially good scans can be found in DFG-funded projects (VD16, VD17, VD18)
- if you cannot find a scan:
    - have it scanned from an institution (can be expensive)
    - your local research library may be able to help you
    - or do-it-yourself:
        - procure your own copy, take the pages apart and scan them
        - scan either in color or (at least) grayscale
        - resolution: preferably 300-400 dpi; higher resolution may not be better (connected components in letter shapes may fall apart)
    - the DFG digitisation guidelines may be helpful

# Some tips for image acquisition

- often books found at Google are also available at a higher resolution at BSB (search BSB first)
- use the BSB OPACplus catalog to search for volumes (results can be filtered for online resources)
- at archive.org, download “single page processed JP2 zip” file rather than pdf or djvu files (the latter are downgraded in resolution)
- avoid binarized images, do your own binarization later on
- publicly available images tend to be downsized 150 dpi “service copies” (pdf or jgp); you can ask for higher resolution original png of tiff images
- you can still OCR 150 dpi material, but if the results are not good enough for you, get 300 dpi scans before you do heavy postcorrection

# Effect of image quality on recognition

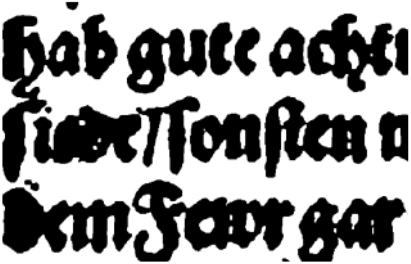

hab gute achti
ſiede/ſonſten u
dem Fewr gar

(a) Google

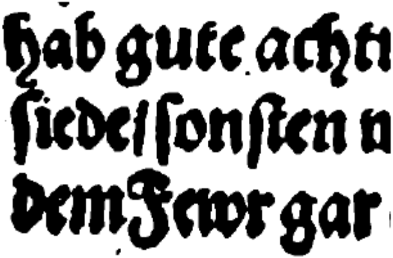

hab gute achti
ſiede/ſonſten u
dem Fewr gar

(b) BSB

- the same scan with lower (Google) and higher (BSB) resolution
- after model training, the accuracy on test pages is 94% (Google) and 97% (BSB)

# Preprocessing

# Preprocessing tasks

- preprocessing consists of (some of) the following tasks:
    - splitting: split double-side images into single pages, or several columns into single-column images
    - cropping: get rid of (black) boundaries
    - deskewing: bring image to horizontal orientation
    - dewarping: “flatten” image, if scanned from warped pages
    - despeckle: noise reduction, suppress black spots (“speckles”)
    - binarization: separate signal (characters, black) from noise (background, white)
    - zoning: separate text zones from non-text (images, graphs etc.); separate semantically different text zones (running heads, page numbers, footnotes, columns, ...)
    - line segment: cut text zones in single text lines
- all OCR engines have some kind of built-in preprocessing facility
- however, for optimal results it is often better to do some manual tool-assisted preprocessing

# Example: Gart der Gesundheit (printing of 1487)

Johann Wonnecke von Kaub (Johannes von Cuba), Gart der Gesundheit (1487)

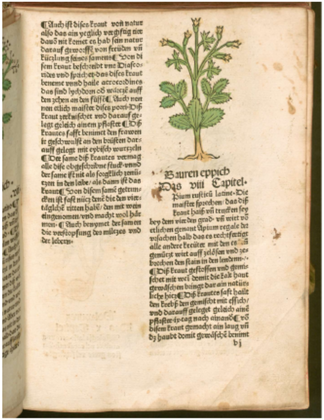

¶ Auch iſt diſes kraut võ natur alſo das ain yeglich vergifftig tier davõ nit komet es hab ſein natur darauf geworffẽ von freüden vñ küczlung ſeines ſamens ¶ Von diſem kraut beſchreibt vns Diaſcorides vnd ſprichet·das diſes kraut beneme vnnd haile acrocordines das ſind lychdorn od̃ wärczẽ auff den zehen an den füſſẽ ¶ Auch nennen etlich maiſter diſes porri·Diß kraut zerkniſchet vnd darauf gelegt geleich ainem pflaſter ¶ Diß krautes ſafft benimet den frawen ir geſchwulſt an den brüſten darauff gelegt mit eybiſch wurczeln ¶ Der ſame diß krautes vermag alle diſe obgeſchribne ſtuck·vnnd der ſame iſt nit als ſorgklich zenüczen in den leibe/ als dann iſt das kraut ¶ Von diſem ſamẽ getruncken iſt faſt nücz denẽ die den viertäglchẽ ritten habẽ/ den mit wein eingenomen/vnd macht wol härmen· ¶ Auch benymet der ſamen die verſtopfung des milczes vnd der lebern·

Bauren eppich

Das viii Capitel·

Pium ruſticũ latine·Die maiſter ſprechen/ das diß kraut haiß vñ trucken ſey bey dem vierden grad· vñ wiert võ etlichen genant Apium regale der vrſachen halb das es rechtfertiget alle andere kreüter mit den es [illegible] gewürczt wiert auff zelöſen vnd zerbrechen den ſtain in den lendenn· ¶ Diß kraut geſtoſſen vnd gemiſchet mit mel domit die kal haut gewäſchen bringt dar ain natürliche hicz ¶ Diß krautes ſaft hailt den krebß den gemiſcht mit eſſich/ vnd darauff geleget geleich ainẽ pflaſter·iy·tag nach ainand ¶ Võ diſem kraut gemacht ain laug vñ dz haubt domit gewäſchẽ benimt

bj

original image

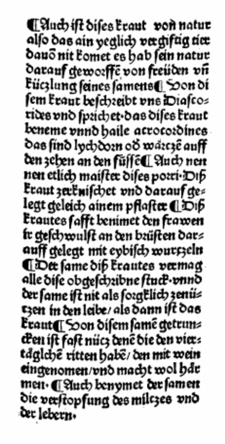

¶ Auch iſt diſes kraut võ natur alſo das ain yeglich vergifftig tier davõ nit komet es hab ſein natur darauf geworffẽ von freüden vñ küczlung ſeines ſamens ¶ Von diſem kraut beſchreibt vns Diaſcorides vnd ſprichet·das diſes kraut beneme vnnd haile acrocordines das ſind lychdorn od̃ wärczẽ auff den zehen an den füſſẽ ¶ Auch nennen etlich maiſter diſes porri·Diß kraut zerkniſchet vnd darauf gelegt geleich ainem pflaſter ¶ Diß krautes ſafft benimet den frawen ir geſchwulſt an den brüſten darauff gelegt mit eybiſch wurczeln ¶ Der ſame diß krautes vermag alle diſe obgeſchribne ſtuck·vnnd der ſame iſt nit als ſorgklich zenüczen in den leibe/ als dann iſt das kraut ¶ Von diſem ſamẽ getruncken iſt faſt nücz denẽ die den viertäglchẽ ritten habẽ/ den mit wein eingenomen/vnd macht wol härmen· ¶ Auch benymet der ſamen die verſtopfung des milczes vnd der lebern·

binarized text zone

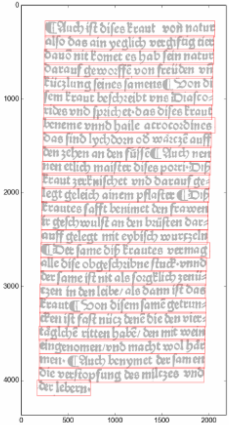

¶ Auch iſt diſes kraut võ natur alſo das ain yeglich vergifftig tier davõ nit komet es hab ſein natur darauf geworffẽ von freüden vñ küczlung ſeines ſamens ¶ Von diſem kraut beſchreibt vns Diaſcorides vnd ſprichet·das diſes kraut beneme vnnd haile acrocordines das ſind lychdorn od̃ wärczẽ auff den zehen an den füſſẽ ¶ Auch nennen etlich maiſter diſes porri·Diß kraut zerkniſchet vnd darauf gelegt geleich ainem pflaſter ¶ Diß krautes ſafft benimet den frawen ir geſchwulſt an den brüſten darauff gelegt mit eybiſch wurczeln ¶ Der ſame diß krautes vermag alle diſe obgeſchribne ſtuck·vnnd der ſame iſt nit als ſorgklich zenüczen in den leibe/ als dann iſt das kraut ¶ Von diſem ſamẽ getruncken iſt faſt nücz denẽ die den viertäglchẽ ritten habẽ/ den mit wein eingenomen/vnd macht wol härmen· ¶ Auch benymet der ſamen die verſtopfung des milczes vnd der lebern·

line segmented

# Effect of preprocessing on recognition (Bodenstein 1557)

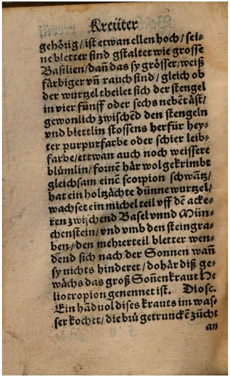

Kreüter
gehöꝛig / iſt etwan ellen hoch / ſei-
ne bletter ſind gſtaltet wie groſſe
Baſilien/ dañ das ſy gröſſer/ weiß
färbiger vñ rauch ſind / gleich ob
der wurtzel theilet ſich der ſtengel
in vier fünff oder ſechs nebẽ äſt/
gewonlich zwiſchẽ den ſtengeln
vnd bletlin ſtoſſens herfür hey-
ter purpurfarbe oder ſchier leib-
farbe/ ettwan auch noch weiſſere
blůmlin/ foꝛnẽ hår wol gekrimbt
gleichſam einẽ ſcoꝛpion ſchwãtz/
hat ein holtzächte dünne wurtzel/
wachſet ein michel teil vff dẽ acke-
ren zwiſchend Baſel vnnd Mün-
chenſtein/ vnd vmb den ſteingra-
ben/ den mehꝛerteil bletter wen-
dend ſich nach der Sonnen wañ
ſy nichts hinderet / dohår diß ge-
wächs das groß Soñenkraut He-
liotropion genennet iſt. Dioſc.
Ein hãduol diſes krauts im waſ-
ſer kochet/ die brů getrunckẽ zücht
an

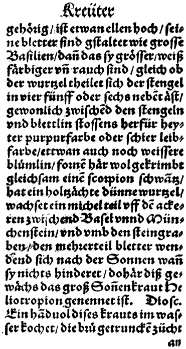

Kreüter
gehöꝛig / iſt etwan ellen hoch / ſei-
ne bletter ſind gſtaltet wie groſſe
Baſilien/ dañ das ſy gröſſer/ weiß
färbiger vñ rauch ſind / gleich ob
der wurtzel theilet ſich der ſtengel
in vier fünff oder ſechs nebẽ äſt/
gewonlich zwiſchẽ den ſtengeln
vnd bletlin ſtoſſens herfür hey-
ter purpurfarbe oder ſchier leib-
farbe/ ettwan auch noch weiſſere
blůmlin/ foꝛnẽ hår wol gekrimbt
gleichſam einẽ ſcoꝛpion ſchwãtz/
hat ein holtzächte dünne wurtzel/
wachſet ein michel teil vff dẽ acke-
ren zwiſchend Baſel vnnd Mün-
chenſtein/ vnd vmb den ſteingra-
ben/ den mehꝛerteil bletter wen-
dend ſich nach der Sonnen wañ
ſy nichts hinderet / dohår diß ge-
wächs das groß Soñenkraut He-
liotropion genennet iſt. Dioſc.
Ein hãduol diſes krauts im waſ-
ſer kochet/ die brů getrunckẽ zücht
an

| | char.acc. | |
|---|---|---|
| OCR engine | orig. | prepr. |
| Tesseract (Fraktur) | 35% | 71% |
| Abbyy (Fraktur + hist. lexicon) | 78% | 79% |

# Preparing the document

- to begin preprocessing, we need single page images in tif or png format
- often you will start from images contained in a single large pdf file or in other formats (jpg, JP2)
- document splitting and format conversion can be done by these open source tools:
    - pdf splitting: PDFtk (Linux: pdftk package)
    - format conversion (choose one of these for batch processing):
        - `convert` from ImageMagick suite
        - `convert` from GraphicsMagick suite
        - `pdftoppm, pdfimages` from Xpdf tools, or (Linux) from poppler-utils package
- if your image is blurred, has an unusual perspective, etc., you can get some help on image preprocessing here:
    - Fred's ImageMagick Scripts (ready-made scripts for a wide variety of tasks)
    - Dan Bloomberg's leptonica package (look at the dewarping example!)
- further preprocessing will be done by ScanTailor

# Example: Goethe, Wahlverwandtschaften (1809)

- available at BSB: Wahlverwandtschaften, vol. 1
- download and rename as `goethe.pdf`
- the following commands assume:
  - a Linux / MacOS system, but similar tools exist for Windows (see above)
  - that you have installed the necessary software (for Debian-flavored Linux variants, this is as easy as step 0)
- step 0: install software (Debian-flavored Linux)

```
$ sudo apt-get install pdftk poppler-utils \
    imagemagick scantailor
```

- step 1: split pdf in single pages

```
$ mkdir pdf
$ pdftk goethe.pdf burst output pdf/%04d.pdf
```

# Example (Goethe): pixel size, convert to png

- step 2: find pixel size of images in pdf
  - for scanned books, pdf is just a container format for included images
  - as a vector format, a pdf does not have a pixel size

```
$ pdfimages -list 0100.pdf
page   num  type   width height color comp bpc  enc
---------------------------------------------------
   1     0 image     714  1283  rgb     3   8  jpeg
```

  - the included jpeg image has 714x1283 pixels
  - for jpeg images in pdf, step 1 is just `pdfimages -j gdg.pdf gdg`

- step 3: convert pdf (or other format) to png

```
$ mkdir png
$ cd pdf
$ for f in pdf; do convert ”$i” ”${i/.pdf/.png]”; done
$ mv *.png ../png
```

# Example (Goethe): resolution

- step 4: find resolution of image (needed as input for ScanTailor)
  - sometimes the scanning resolution (dpi) is given in metadata (archive.org)
  - if you know the physical size of your page:
    divide pixel height (or width) by height (or width) in inch (1 in = 2.54 cm)
  - png image has 714x1283 pixels (same as jpeg;
    otherwise use convert with –density option)
  - take pixel measurements from png image with ruler (last page) at 100% image size (okular or other viewer)
  - rule of thumb: height of 6 text lines ca. 1 inch
  - pixels per inch (ppi, used in imaging) correspond to dots per inch (dpi, used in printing)

# Example (Goethe): resolution (cont'd)

in DFG scans, a ruler was scanned with one of the last pages:
measure ruler size in pixels

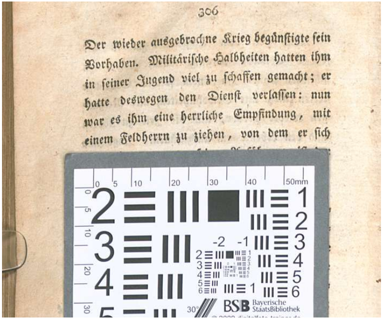

306

Der wieder ausgebrochne Krieg begünſtigte ſein Vorhaben. Militäriſche Halbheiten hatten ihm in ſeiner Jugend viel zu ſchaffen gemacht; er hatte deswegen den Dienſt verlaſſen: nun war es ihm eine herrliche Empfindung, mit einem Feldherrn zu ziehen, von dem er ſich

0
5
10
20
30
40
50mm
BSB Bayerische StaatsBibliothek

- here: 355 pixels/(5/2.54) inch = 180 ppi
- not ideal resolution, but this is what we got
- resolution of 150 .. 180 dpi to be expected for downloadable files (lower size saves bandwidth)

# Example (Goethe): ScanTailor

Convert png image into binarized tif using ScanTailor

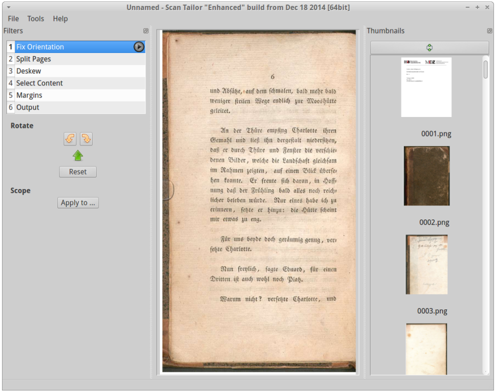

6

und Abſätze, auf dem ſchmalen, bald mehr bald weniger ſteilen Wege endlich zur Mooshütte geleitet.

An der Thüre empfing Charlotte ihren Gemahl und ließ ihn dergeſtalt niederſitzen, daß er durch Thüre und Fenſter die verſchiedenen Bilder, welche die Landſchaft gleichſam im Rahmen zeigten, auf einen Blick überſehen konnte. Er freute ſich daran, in Hoffnung daß der Frühling bald alles noch reichlicher beleben würde. Nur eines habe ich zu erinnern, ſetzte er hinzu: die Hütte ſcheint mir etwas zu eng.

Für uns beyde doch geräumig genug, verſetzte Charlotte.

Nun freylich, ſagte Eduard, für einen Dritten iſt auch wohl noch Platz.

Warum nicht? verſetzte Charlotte, und

ScanTailor with png of original image

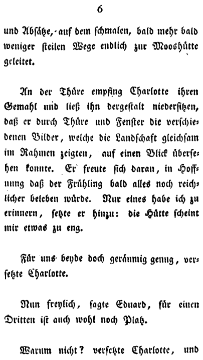

6

und Abſätze,-auf dem ſchmalen, bald mehr bald weniger ſteilen Wege endlich zur Mooshütte geleitet.

An der Thüre empfing Charlotte ihren Gemahl und ließ ihn dergeſtalt niederſitzen, daß er durch Thüre und Fenſter die verſchiedenen Bilder, welche die Landſchaft gleichſam im Rahmen zeigten, auf einen Blick überſehen konnte. Er freute ſich daran, in Hoffnung daß der Frühling bald alles noch reichlicher beleben würde. Nur eines habe ich zu erinnern, ſetzte er hinzu: die Hütte ſcheint mir etwas zu eng.

Für uns beyde doch geräumig genug, verſetzte Charlotte.

Nun freylich, ſagte Eduard, für einen Dritten iſt auch wohl noch Platz.

Warum nicht? verſetzte Charlotte, und

tif image as result of preprocessing

# Example (Goethe): recognition compared

character vs. word accuracy in %:

| | char. | | word | |
|---|---|---|---|---|
| OCR engine | png | tif | png | tif |
| Tesseract | 86.42 | 96.06 | 68.18 | 84.55 |
| OCRopus | 95.33 | 96.06 | 82.73 | 89.09 |
| Abbyy FR 11 | 96.79 | 95.33 | 92.73 | 91.82 |

## Conclusion

- for 19th century Fraktur printings, ca. 95% character accuracy can be achieved by any engine (without training)
- separate preprocessing makes a difference for character (Tesseract) and word accuracies (Tesseract, OCRopus)
- Abbyy has very good automatic preprocessing, separate preprocessing is unnecessary